

ZAMAN SERİLERİ VERİLERİYLE REGRESYON ANALİZİNDE EK KONULAR

Hüseyin Taştan¹

¹Yıldız Teknik Üniversitesi
İktisat Bölümü

Ders Kitabı:
Introductory Econometrics: A Modern Approach (4th ed.)
J. Wooldridge

14 Mart 2013

Zaman Serileri Verileriyle Regresyon Analizinde Ek Konular

- Bölüm 10'da zaman serileri için OLS'nin sonlu (finite) örneklem özelliklerini gördük.
- Oldukça katı TS.1-TS.6 varsayımları sağlandığında zaman serilerinden elde edilen OLS tahmin edicileri, kesitler-arası verilerden elde edilen OLS tahmin edicilerle aynı özelliklere sahip olacaklardır.
- Zaman serilerinde de kesitler-arasında olduğu gibi OLS'nin büyük örneklem (asimptotik) özelliklerini incelemekte yarar olacaktır.
- Örneğin, hata teriminin normal dağılmadığı durumda merkezi limit teoremine dayanarak OLS test istatistiklerini kullanabileceğiz.

Zaman Serileri Verileriyle Regresyon Analizinde Ek Konular

- Zaman serilerinde örneklem hacmi genellikle sınırlı olmasına rağmen, başka çözüm olmadığı için büyük örneklem özelliklerinden sık sık yararlanacağız.
- Altbölüm 11.2'de bağımlı değişkenin gecikmeli halinin, y_{t-1} gibi, açıklayıcı değişken olarak kullanılmasının kesin dışsallık (strict exogeneity) varsayımını (TS.2) nasıl ihlal ettiğini göreceğiz.
- Kesitler-arası verilerde (CH 5) rassal örnekleme (random sampling) varsayımı OLS büyük örneklem özelliklerini türetmemizde çok yardımcı olmuştur.
- Zaman serilerinde ise gözlemler ileri ve geriye doğru zaman içerisinde ilişkili oldukları için işimiz çok daha zor olacaktır.
- Zaman serilerinde kritik nokta, **değişkenlerin farklı dönemlere ait değerleri arasındaki korelasyonun yeterince hızlı sıfıra düşüp düşmediğidir.**

Durağan (Stationary) ve Durağan Olmayan (Nonstationary) Zaman Serileri

- Bu bölümde regresyon analizinde geleneksel büyük örneklem yaklaşımlarını (approximations) uygulayabilmemiz için bize gerekli olan anahtar kavramları göreceğiz.
- Zaman serileri analizinde "durağan süreç" (stationary process) kavramı tarihsel olarak çok büyük bir rol oynamıştır.
- Durağan süreç olasılık dağılımı zaman içinde kararlı (stable) olan süreçlere denir. Durağan süreçten alınacak herhangi bir rassal değişkenler dizisi ile $h \geq 1$ dönem sonra alınacak ikinci bir dizinin ortak (joint) dağılımları aynıdır.

Durağan ve Durağan Olmayan Süreçler

Tanım: Kesin Durağan Stokastik Süreç

$\{x_t : t = 1, 2, \dots\}$ stokastik süreci, bütün $1 \leq t_1 \leq t_2 \leq \dots \leq t_m$ zaman endeksleri kümesi için, $(x_{t_1}, x_{t_2}, \dots, x_{t_m})$ 'in ortak dağılımı ile, her $h \geq 1$ için, $(x_{t_1+h}, x_{t_2+h}, \dots, x_{t_m+h})$ 'in ortak dağılımı aynıysa, (kesin) durağandır.

- ▶ Başka bir deyişle, zaman serisi dizisi özdeş (identically) dağılmıştır.

Tanım: Kovaryans Durağan Süreç

Sonlu ikinci momente ($E(x_t^2) < \infty$) sahip, $\{x_t : t = 1, 2, \dots\}$ stokastik süreci, şu üç şartı sağlıyorsa kovaryans durağandır:

1. $E(x_t)$ sabittir (zamandan bağımsız)
2. $\text{Var}(x_t)$ sabittir (zamandan bağımsız)
3. Her t dönemi ve $h \geq 1$ için, $\text{Cov}(x_t, x_{t+h})$ h 'ye bağlıdır ancak t 'ye bağlı değildir.

Kovaryans Durağanlık Kavramı

- ▶ Kovaryans durağanlık (**covariance stationarity**), stokastik sürecin ilk iki momentinin, yani, ortalama ve varyansının, zaman içinde sabit olmasını gerektirir.
- ▶ Ayrıca x_t ve x_{t+h} arasındaki kovaryansın (ve dolayısıyla korelasyonunun) iki süreç arasındaki uzaklık olan h 'ye bağlı olmasını ve t 'ye bağlı olmamasını gerektirir.
- ▶ Kovaryans durağanlık zayıf durağanlık olarak da isimlendirilir.
- ▶ Kovaryans durağanlıktan daha katı koşullara sahip kesin durağanlık (**strict stationarity**) tanımı üzerinde durmayacağız.
- ▶ Durağanlık denince kovaryans-durağanlık tanımını anlayacağız.

Durağanlık Kavramı

- ▶ Regresyon analizinde durağanlığın işlevi çok önemlidir.
- ▶ Teorik olarak, durağanlık, "büyük sayılar yasası (**the law of large numbers, LLN**)" ve "merkezi limit teoremi (**central limit theorem, CLT**)" önermelerini basit hale getirir.
- ▶ Pratikte ise, iki değişken arasında regresyon ilişkisi tesis edebilmek için serilerin zaman içinde kararlılığı (**stability**) ile ilgili bazı varsayımlar yapmamız gerekir.
- ▶ Eğer x_t ve x_{t+h} değişkenleri zaman içinde keyfi olarak değişiyor ise, zaman serilerinde bu değişkenlerin sadece tek bir realizasyonları elimizde olduğu için, birbirlerine etkilerini sağlıklı olarak ölçemeyiz.
- ▶ Çoklu zaman serisi regresyonlarında β_j katsayılarının zaman içinde değişmemesi için belli bir durağanlık (stationarity) varsayımına ihtiyaç duymaktayız.
- ▶ Ayrıca, TS.4 ve TS.5 varsayımları, hata terimleri varyansının zaman içinde sabit olmasını ve zaman itibarıyla ard arda gelen (**adjacent**) u 'ların ilişkisiz olmasını gerektirir.

Zayıf Bağımlı Zaman Serileri


- ▶ Eğer aşağıdaki koşul sağlanıyorsa, x_t ve x_{t+h} durağan dizileri (sequences) asimptotik olarak ilişkisizdirler (**asymptotically uncorrelated**).

$$h \rightarrow \infty \quad \text{iken} \quad \text{Corr}(x_t, x_{t+h}) \rightarrow 0$$

- ▶ Pratikte, korelasyonların yeterince hızlı bir şekilde sifıra gidip gitmediklerine bakılır.
- ▶ Zayıf Bağımlılık, büyük sayılar yasası (LLN) ve merkezi limit teoremi (CLT)'nin sağlanmalarında rassal örnekleme (random sampling) varsayımının üstlendiği görevi görmektedir.
- ▶ Zaman serileri verileriyle ilgili merkezi limit teoremi, durağanlık ve zayıf bağımlılığı bir önkoşul olarak getirmektedir. Dolayısıyla, bu tür seriler çoklu regresyon için ideal serilerdir.

Zayıf Bağımlı Zaman Serileri

- Zayıf bağımlı (**weakly dependent**) zaman serisine bir örnek **i.i.d (independently and identically distributed)** silsilesidir.
- Örneğin, normal dağılım tablosundan rasgele çekilmiş bir seri böyledir.
- Aşağıdaki grafikte standart normal dağılımdan çekilmiş 100 elemanlı bir zaman serileri dizisi gösterilmiştir.



Pür Rassal Süreç (White Noise Process)

- $\{e_t : t = 1, 2, \dots\}$ ile gösterilen bir stokastik süreç aşağıdaki koşulları sağlıyorsa pür rassal süreç (white noise process) adı verilir:

$$\begin{aligned} E[e_t] &= 0 \\ \text{Var}(e_t) &= \sigma_e^2 \\ \text{Cov}(e_t, e_s) &= 0, \quad t \neq s \end{aligned}$$

Bu süreci kısaca $e_t \sim wn(0, \sigma_e^2)$ ile göstereceğiz.

- Yukarıdaki koşullara ek olarak $\{e_t\}_{t=1}^T$ süreci ortalaması 0 ve varyansı σ_e^2 olan bir normal dağılıma uyuyorsa bu sürece Normal (Gaussian) Pür Rassal Süreç adı verilir ve $e_t \sim GWN(0, \sigma_e^2)$ ile gösterilir. Eğer türdeş ve bağımsız (iid) dağılıyorsa kısaca $e_t \sim iid N(0, \sigma_e^2)$ ile gösterilir.

Örnek: Hareketli Ortalama (Moving Average - MA) Süreci

- **MA(1)**, birinci sıradan bir hareketli ortalama süreci aşağıdaki gibi tanımlanır:

$$x_t = e_t + \alpha_1 e_{t-1}, \quad t = 1, 2, \dots$$

e_t iid pür rassal süreç (white noise) olarak tanımlıdır.

- Burada, x_t, e_t ve e_{t-1} 'in ağırlıklı toplamıdır.
- MA(1)'de komşu x terimleri ilişkilidir. Örneğin, yukarıdaki denklemi $t + 1$ dönemi için yazarsak:

$$x_{t+1} = e_{t+1} + \alpha_1 e_t \quad \text{olur.}$$

- Bu sürecin (koşulsuz) beklenen değeri alınırsa:

$$\begin{aligned} E(x_t) &= E(e_t + \alpha_1 e_{t-1}) \\ &= E(e_t) + \alpha_1 E(e_{t-1}) = 0 \equiv \mu \end{aligned}$$

MA(1) Süreci

- MA(1) sürecinin varyansı:

$$\begin{aligned} \text{Var}(x_t) &= E[(x_t - E(x_t))^2] = E(x_t^2) \\ &= E((e_t + \alpha_1 e_{t-1})^2) \\ &= E(e_t^2) + \alpha_1^2 E(e_{t-1}^2) \\ &= \sigma_e^2 + \alpha_1^2 \sigma_e^2 = (1 + \alpha_1^2) \sigma_e^2 \end{aligned}$$

- Birinci otokovaryans:

$$\begin{aligned} \text{Cov}(x_t, x_{t-1}) &= E[(x_t - \mu)(x_{t-1} - \mu)] \\ &= E[(e_t + \alpha_1 e_{t-1})(e_{t-1} + \alpha_1 e_{t-2})] \\ &= E[e_t e_{t-1} + \alpha_1 e_t e_{t-2} + \alpha_1 e_{t-1}^2 + \alpha_1^2 e_{t-1} e_{t-2}] \\ &= E(e_t e_{t-1}) + \alpha_1 E(e_t e_{t-2}) + \alpha_1 E(e_{t-1}^2) \\ &\quad + \alpha_1^2 E(e_{t-1} e_{t-2}) \\ &= 0 + 0 + \alpha_1 E(e_{t-1}^2) + 0 \\ &= \alpha_1 \sigma_e^2 \end{aligned}$$

MA(1) Süreci

- Birinci otokorelasyon:

$$\text{Corr}(x_t, x_{t-1}) = \frac{\text{Cov}(x_t, x_{t-1})}{\text{Var}(x_t)} = \frac{\alpha_1}{1 + \alpha_1^2}$$

- Birinci otokorelasyonun işareti α_1 katsayısının işaretine bağlıdır.
- Örneğin, eğer $\alpha_1 = 0.5$ ise, $\text{Corr}[x_t, x_{t-1}] = 0.40$ olacaktır.
- $\alpha_1 = 1$ iken korelasyon MA(1) için en yüksek değerine, 0.5, ulaşacaktır.

MA(1) Süreci

- Komşu x_t ve x_{t+1} terimleri ilişkili çıkmasına rağmen birbirlerine daha uzak x terimleri ilişkisizdir.
- Örneğin, $x_{t+2} = e_{t+2} + \alpha_1 e_{t+1}$ değişkeni x_t değişkeni ile ilişkisizdir.
- Çünkü e_t zaman içinde kendi geçmiş ve gelecek değerleriyle ilişkisizdir.
- Ayrıca e_t özdeş (identical) dağıldığı için MA(1) durağan bir süreçtir. Ortalama, varyans ve otokovaryanslar zamana bağlı değildir.
- Bunun yanı sıra zayıf bağımlı (weakly dependent) bir süreçtir. Bu nedenle, x_t sürecine LLN ve CLT uygulanabilecektir.

1. Dereceden Otoregresif Süreç-AR(1) Süreci

$$y_t = \rho_1 y_{t-1} + e_t, \quad t = 1, 2, \dots$$

- Serinin başlangıç noktası y_0 'dır ($t = 0$ iken). $e_t : t = 1, 2, \dots$ sıfır ortalamalı ve σ_e^2 varyanslı i.i.d bir seridir (white noise - pür rassal süreç). Ayrıca e_t 'nin y_0 'dan bağımsız olduğunu ve y_0 'ın beklenen değerinin sıfır olduğunu varsayıyoruz, $E(y_0) = 0$. **Bu sürece, 1. dereceden otoregresif süreç denir [AR(1)].**
- AR(1) sürecinde $|\rho_1| < 1$ **koşulu**, hem sürecin kararlılık (**stability**) hem de zayıf bağımlılık (**weak dependence**) koşuludur.
- Durağan bir AR(1) sürecinde (yani, $|\rho_1| < 1$ iken):

$$\sigma_y^2 = \sigma_e^2 / (1 - \rho_1^2)$$

AR(1) Süreci

- σ_y^2 hem y_t hem de y_{t+h} 'in standart sapması olduğu için, $h \geq 1$ iken ikisi arasındaki korelasyon şöyle bulunabilir:

$$\text{Corr}(y_t, y_{t+h}) = \text{Cov}(y_t, y_{t+h}) / (\sigma_y \sigma_y) = \rho_1^h$$

- Buna göre, $\text{Corr}(y_t, y_{t+1}) = \rho_1$ serideki herhangi iki ardışık terim arasındaki korelasyon katsayısıdır.
- $\text{Corr}(y_t, y_{t+h})$ formülü, y_t ve y_{t+h} 'in korelasyonlarının sıfır olmadığını ancak bu korelasyonun h büyüdükçe sıfıra doğru gittiğini gösterir.

$$|\rho_1| < 1 \text{ olduğundan, } h \rightarrow \infty \text{ iken } \rho_1^h \rightarrow 0$$

- Örneğin, $\rho_1 = 0.9$ iken, $\text{Corr}(y_t, y_{t+20}) = 0.122$ olacaktır.
- Yani, durağan AR(1) modeli zayıf bağımlıdır (weakly dependent).

Trend-Durağan (Trend-Stationary) Süreç


- Trend içeren tüm seriler durağan-olmayan nitelikte seriler değildir.
- Bazı seriler belli bir trend etrafında durağandılar.
- Yani, trendleri alınınca geriye kalan kısım durağandır.
- Bunlara trend-durağan (trend-stationary) seri denir. Bu seriler aynı zamanda zayıf-bağımlıdır.
- Deterministik doğrusal trend süreci:

$$y_t = \beta_0 + \beta_1 t + \epsilon_t, \quad \epsilon_t \sim wn(0, \sigma^2)$$

Örnek: Deterministik doğrusal trend süreci

$$y_t = \beta_0 + \beta_1 t + \epsilon_t, \quad \epsilon_t \sim wn(0, \sigma^2)$$

Şekil: Eğimleri farklı iki doğrusal trend serisi



Zaman Serilerinde SEKK(OLS) Tahmin Edicilerin Asimptotik Özellikleri

- Ch.10'da bazı zaman serileri problemlerinde doğrusal klasik model varsayımlarının ihlal edildiğini gördük.
- Bu durumda yine OLS'nin büyük örneklem özelliklerine başvuracağız.
- Bazı varsayımları yumuşatarak OLS'nin tutarlı tahmin ediciler verdiğini göstereceğiz.

TS.1' Doğrusallık ve Zayıf-Bağımlılık

- TS.1 varsayımı modelin β parametreleri bakımından doğrusal olduğunu söylüyordu.
- Eğer x değişkenleri arasında y_{t-1} , y_{t-2} vb. gibi gecikmeli bağımlı değişken varsa, TS.1 şöyle değişecektir:

Varsayım TS.1': Doğrusallık ve Zayıf-Bağımlılık

Varsayım TS.1', $\{(x_t, y_t) : t = 1, 2, \dots\}$ 'in zayıf-bağımlı olduğunu ilave edersek TS.1 ile aynıdır. Başka bir deyişle, büyük sayılar yasası, LLN, ve merkezi limit teoremi, CLT, örneklem ortalamalarına uygulanabilir.

TS.2' Sıfır Koşullu Ortalama

- u_t ile x 'in tüm geçmiş, şimdiki ve gelecek değerlerinin ilişkili olmasını yasaklayan TS.2 varsayımı yerine daha yumuşak olan şu varsayımı yapacağız.

Varsayım TS.2': Sıfır Koşullu Ortalama

Her t zamanı için, $E(u_t|x_t) = 0$.

- Yani, hata terimleriyle x değişkenleri sadece cari dönem, t , itibarıyla ilişkilidir.

$$E(u_t) = 0, \quad Cov(x_{tj}, u_t) = 0, \quad j = 1, \dots, k.$$

TS.3' Tam Çoklu-Doğrusallığın Olmaması

- Bu varsayım aynıdır

Varsayım TS.3': Tam Çoklu-Doğrusallığın Olmaması

Varsayım TS.3 ile aynıdır.

- **Bu üç varsayım sağlanıyorsa OLS tahmin edicileri tutarlıdır:**

Teorem 11.1 (OLS'nin Tutarlılığı)

TS.1', TS.2' ve TS.3' altında OLS tahmin edicileri tutarlıdır: $\text{plim } \hat{\beta}_j = \beta_j, j=0,1,\dots,k$.

OLS tahmin edicilerinin tutarlılığı

- Bölüm 10'da gördüğümüz Teorem 10.1 ile Teorem 11.1 arasında önemli farklılıklar vardır.
- Teorem 11.1'de tutarlılık sağlanmaktadır, sapmasızlık değil.
- Teorem 11.1'de x 'ler kesin dışsal değil sadece dışsaldırlar (exogenous).
- Bu yumuşatmayı değişkenlerin weak dependent olduğunu varsayarak yapabildik.

Örnek

- Aşağıdaki örnekte z_{t1} , para arzı aylık büyüme hızı; y_t enflasyon oranıdır.

$$y_t = \beta_0 + \beta_1 z_{t1} + \beta_2 z_{t2} + u_t$$

$$E(u_t|z_{t1}, z_{t2}) = 0.$$

- Geçen ayın enflasyon oranı bu ayın para arzı artış oranını etkilesin.

$$z_{t1} = \delta_0 + \delta_1 y_{t-1} + v_t$$

- Buna rağmen z_{t1} 'i açıklayıcı değişken olarak kullanabileceğiz.

Örnek (devam)

- Önceki modelde OLS'nin tutarlı olması için şu varsayım şarttır:

$$E(u_t | z_{t1}, z_{t2}) = 0.$$

- Bu varsayım, u_t 'de yer alan göz ardı edilen faktörlerin z_{t1} ve z_{t2} ile ilişkili olmasına izin vermemektedir.
- Buna karşın, hata teriminin gecikme değerleri ile açıklayıcı değişkenler, örneğin u_{t-1} ile z_{t1} , ilişkili olabilir.
- Kesit-veri analizinde olduğu gibi yanlış fonksiyon kalıbı seçimi, açıklayıcı değişkenlerdeki ölçme hataları bu varsayımın geçersiz olmasına neden olur.

Example 11.2: Sonlu Dağıtılmış Gecikme Modeli

- Sonlu dağıtılmış gecikme modeli (finite distributed lag model):

$$y_t = \alpha_0 + \delta_0 z_t + \delta_1 z_{t-1} + \delta_2 z_{t-2} + u_t$$

- u_t 'nin beklenen değerinin, z 'nin şimdiki, ve geçmiş değerlerine koşullu olarak 0 olduğunu varsayıyoruz:

$$E(u_t | z_t, z_{t-1}, z_{t-2}, z_{t-3}, \dots) = 0$$

- Buna göre, z_t, z_{t-1} ve z_{t-2} modele eklendiğinde, z 'nin daha sonraki gecikmeleri $E(u_t | z_t, z_{t-1}, z_{t-2}, z_{t-3}, \dots)$ 'yi etkilemez; eğer etkiliyor olsaydı modele daha ileri gecikmeleri eklememiz gerekirdi.
- $X_t = (z_t, z_{t-1}, z_{t-2})$ dersek, TS.2' varsayımı sağlanmış olur, böylece OLS tutarlı olacaktır.

Example 11.3: AR(1) Modeli

- Aşağıdaki AR(1) modelini göz önünde bulunduralım:

$$y_t = \beta_0 + \beta_1 y_{t-1} + u_t$$

- Burada hata terimi u_t 'nin, y 'nin tüm geçmiş değerlerine koşullu beklenen değeri:

$$E(u_t | y_{t-1}, y_{t-2}, \dots) = 0$$

- İki eşitliği birleştirirsek

$$E(y_t | y_{t-1}, y_{t-2}, \dots) = E(y_t | y_{t-1}) = \beta_0 + \beta_1 y_{t-1}$$

AR(1) Süreci

- AR(1) modelinde u_t ile açıklayıcı değişken y_{t-1} ilişkisiz, buna karşılık u_t ile y_t ilişkiliydi.
- Dolayısıyla, kesin dışsallık (strict exogeneity) burada sağlanamaz.
- Zayıf bağımlılık (weak dependence) sağlandığı için AR(1)'den tutarlı tahmin ediciler elde ediyoruz, ancak bunlar sapmalıdır.
- Örnek hacmi küçükken ya da ρ_1 bire yakinken bu sapma ciddi boyuta ulaşır.

TS.4' Sabit Varyans Varsayımı ve TS.5' Otokorelasyon Olmaması Varsayımı

Varsayım TS.4': Sabit Varyans

Her t zamanı için, $Var(u_t|X_t) = \sigma^2$.

Varsayım TS.5': Otokorelasyon olmaması

Her $t \neq s$ için, $E(u_t u_s | X_t, X_s) = 0$.

- ▶ TS.4'de sadece cari, t , dönem x değerlerine göre koşullandırma yapılmıştır, tüm t dönemlerine göre değil.
- ▶ TS.5'de de u_t ve u_s ile çakışan x değerleri bakımından koşullandırma (conditioning) yapılmıştır.

OLS'nin Asimptotik Normallliği

Teorem 11.2: OLS'nin Asimptotik Normallliği

TS.1'-TS.5' varsayımları altında, OLS tahmin edicileri asimptotik olarak normal dağılırlar. Buna ilaveten, OLS standart hataları, t istatistikleri, F istatistikleri ve LM istatistikleri asimptotik olarak geçerlidir.

- ▶ TS.1'-TS.5' varsayımları altında kesitler-arası verideki ile hemen hemen aynı bir asimptotik sonuç türettik.
- ▶ Doğrusal klasik model varsayımları ihlal edildiğinde eğer örnek hacmimiz büyük ise ve yukarıdaki yeni varsayım kümesi sağlanıyor ise, OLS tutarlıdır ve hipotez testleri (inference) yapılabilir.
- ▶ Devamında, zayıf bağımlılık (weak dependence) varsayımının ihlalini, Ch.12'de de ardışık bağımlılık (serial correlation) ve değişen varyansı (heteroscedasticity) ele alacağız.

Example 11.4: Etkin Piyasa Hipotezi

- ▶ Etkin piyasa hipotezinin (Efficient Market Hypothesis) katı bir formuna göre t haftası öncesindeki gözlenen bilgiler t haftasındaki getiriyi tahmin etmekte fayda sağlamamalıdır. Eğer sadece y 'nin geçmiş değerlerini kullanıyorsak, etkin piyasa hipotezi şöyle ifade edilebilir:

$$E(y_t | y_{t-1}, y_{t-2}, \dots) = E(y_t)$$

- ▶ Eğer bu ifade yanlışsa, bugünkü getiriyi tahmin etmede geçmişteki haftalık getirilerle ilgili bilgiyi kullanabiliriz. Etkin piyasa hipotezine göre, bu yatırım fırsatlarının farkına varılacak ve bu fırsatlar anlık olarak ortadan kalkacaktır.

$$\widehat{\text{return}} = 0.180 + 0.059 \text{return}_{t-1}$$

(0.081) (0.038)

$$n = 689 \quad R^2 = 0.0035 \quad \bar{R}^2 = 0.0020$$

Etkin Piyasa Hipotezi: AR(2) Modeli

- ▶ Borsa getirileri için aşağıdaki AR(2) modeli kurulmuş olsun:

$$y_t = \beta_0 + \beta_1 y_{t-1} + \beta_2 y_{t-2} + u_t$$

$$E(u_t | y_{t-1}, y_{t-2}, \dots) = 0$$

- ▶ β_1 ve β_2 'nin birlikte anlamlı olup olmadığını test etmek için boş hipotezimiz:

$$H_0 : \beta_1 = \beta_2 = 0$$

- ▶ Sabit varyans varsayımını da eklersek, $Var(u_t | y_{t-1}, y_{t-2}) = \sigma^2$, boş hipotezi test etmek için standart F istatistiğini kullanabiliriz. Boş hipotezin reddedilememesi Etkin Piyasa Hipotezinin geçerli olduğu yönünde kanıt sağlayacaktır.
- ▶ Modelin tahmini sonucu, F istatistiği yaklaşık olarak $F = 1.65$, karşılık gelen p değeri ise yaklaşık 0.193 çıkmaktadır. Buna göre boş hipotezi %15 anlamlılık düzeyinde bile reddedemiyoruz.

Example 11.5: Beklentilerle Genişletilmiş Phillips Eğrisi

- ▶ Beklentilerle genişletilmiş Phillips eğrisinin (expectations augmented Phillips curve) doğrusal bir versiyonu aşağıdaki gibi yazılabilir:

$$\inf_t - \inf_t^e = \beta_1(unem_t - \mu_0) + e_t$$

- ▶ Bu denklemde, μ_0 doğal işsizlik oranını, \inf_t^e ise beklenen enflasyon oranını ifade etmektedir. Beklenen enflasyon oranının bir önceki yılın enflasyon oranına eşit olduğunu varsayarsak model aşağıdaki gibi yazılabilir:

$$\inf_t - \inf_{t-1} = \beta_0 + \beta_1 unem_t + e_t$$

- ▶ sol tarafı enflasyon oranının değişimi olarak ifade edersek:

$$\Delta \inf_t = \beta_0 + \beta_1 unem_t + e_t$$

- ▶ Burada, $\Delta \inf_t = \inf_t - \inf_{t-1}$ ve $\beta_0 = -\beta_1 \mu_0$ 'dır. Yani, adaptif beklentiler altında, beklentilerle genişletilmiş Phillips eğrisi, enflasyon oranındaki değişim ile işsizlik oranı ve e_t ile ifade edilen bir arz şoku arasındaki ilişkiyi gösterir.

Example 11.5: Beklentilerle Genişletilmiş Phillips Eğrisi

$$\widehat{\Delta \inf_t} = \frac{3.03}{(1.38)} - \frac{0.543}{(0.230)} unem_t$$

$$n = 48 \quad R^2 = 0.108 \quad \bar{R}^2 = 0.088$$

- ▶ Çevrimsel (cyclical) işsizlik ile beklenilmeyen enflasyon arasındaki ödünleşme (trade off) regresyon ile tahmin edilmiştir: $unem_t$ 'deki bir puanlık artış beklenmeyen enflasyonu yaklaşık yarım puan azaltmaktadır. Etki istatistiki olarak anlamlıdır (çift taraflı p değeri yaklaşık 0.023).
- ▶ Doğal işsizlik oranının, $\mu_0 = \beta_0 / (-\beta_1)$, bir tahminini bu regresyon yardımıyla elde edebiliriz:
 $\hat{\mu}_0 = \hat{\beta}_0 / (-\hat{\beta}_1) = 3.03 / 0.543 = 5.58$
- ▶ Doğal işsizlik oranı yaklaşık 5.6 olarak hesaplanmıştır ki bu makroekonomi literatüründe kabul edilenle örtüşmektedir (yaklaşık %5 – 6)

Güçlü Bağımlı Zaman Serileri

- ▶ Zaman serileri zayıf bağımlı olduğu zaman OLS çıkarsama prensiplerinin klasik varsayımlardan daha zayıf varsayımlar altında geçerli olduklarını gördük.
- ▶ Ancak bir çok iktisadi zaman serileri zayıf bağımlı olmaktan ziyade güçlü-bağımlı olarak sınıflandırılır.
- ▶ Yani, zaman serileri geçmiş değerleriyle yüksek dereceden ilişkilidir (highly persistent, strongly dependent).
- ▶ Bu alt bölümde, bu türden zaman serileri örneklerini inceleyeceğiz.

Güçlü Bağımlı Zaman Serileri

- ▶ Pek çok ekonomik zaman serisi "Kuvvetli şekilde bağımlı" (**strongly dependent**) ya da başka deyişle "kuvvetlice yapışkan" (**highly persistent**) serilerdir. Örnek, enflasyon oranı, bütçe açıkları vb.
- ▶ Ch.10'daki CLM varsayımları sağlanıyorsa **strongly dependent** serilerin regresyonda kullanımı sorun çıkarmaz. Ancak, veri, **weakly dependent** değilse bu varsayımlarda ufak bir bozulma LLN ve CLT'in uygulanmasını imkansız kılacaktır.
- ▶ AR(1) modelinde ρ_1 katsayısı 1'e doğru gittikçe serinin yapışkanlığı artmaktadır.
- ▶ $\rho_1 = 1$ olduğunda AR(1) süreci **rassal yürüyüş** (random walk) süreci adını alır.

Rassal Yürüyüş (Random Walk)

- $\rho_1 = 1$ iken AR(1) modeli aşağıdaki gibi yazılabilir:

$$y_t = y_{t-1} + e_t, t = 1, 2, \dots$$

- $\{e_t : t = 1, 2, \dots\}$ sıfır ortalamalı ve σ_e^2 varyanslı i.i.d bir seridir. Başlangıç değerinin, y_0 , her $t \geq 1$ için e_t 'den bağımsız olduğunu varsayalım.
- y_t 'nin beklenen değerini yinelemeli yerine koyma (repeated substitution) yöntemi ile bulabiliriz:

$$y_t = e_t + e_{t-1} + e_{t-2} + \dots + e_1 + y_0$$

- Her iki tarafın beklenen değerini alalım:

$$E(y_t) = E(e_t) + E(e_{t-1}) + E(e_{t-2}) + \dots + E(e_1) + E(y_0)$$

$$E(y_t) = E(y_0)$$

- Random walk sürecinin beklenen değeri t'ye bağımlı değildir (zamandan bağımsız). Eğer başlangıç değeri $y_0 = 0$ varsayılırsa, her $t \geq 1$ için $E(y_t) = 0$ olacaktır.

Yinelemeli Yerine Koyma Yöntemi (Repeated Substitution): $y_t = y_{t-1} + e_t$

- $y_1 = y_0 + e_1$
- $y_2 = y_1 + e_2 = y_0 + e_1 + e_2$
- $y_3 = y_2 + e_3 = y_0 + e_1 + e_2 + e_3$
-
- $y_t = y_0 + e_1 + e_2 + \dots + e_{t-1} + e_t = y_0 + \sum_{i=1}^t e_i$

Rassal Yürüyüş (Random Walk)

- Random Walk sürecinin beklenen değeri sıfır olduğu halde varyansı t ile birlikte (t'nin bir fonksiyonu olarak) artmaktadır.

$$Var(y_t) = Var(e_t) + Var(e_{t-1}) + \dots + Var(e_1) = \sigma_e^2 t$$

- Random Walk süreci güçlü derecede yapışkanlık (high persistence) gösterir, öyle ki, bugünkü y, uzak gelecekteki (h dönem sonraki) y değerini belirlemede önem arz etmektedir. h dönem sonrasını ele alalım:

$$y_{t+h} = e_{t+h} + e_{t+h-1} + \dots + e_{t+1} + y_t$$

- t döneminde, y_t değerine koşullu olarak y_{t+h} 'in beklenen değerini bulalım. e_{t+j} 'nin beklenen değeri, y_t veri iken, her $j \geq 1$ için sıfır olduğundan, her $h \geq 1$ için:

$$E(y_{t+h}|y_t) = y_t$$

Rassal Yürüyüş (Random Walk)

- Demek ki, random walk'de bizim gelecekle, y_{t+h} , ilgili yapabileceğimiz en iyi tahmin bugünkü, y_t , değeridir.
- Oysa, bu tahmin, kararlı AR(1) sürecinde, yani $|\rho_1| < 1$ iken, $h \rightarrow \infty$ giderken sıfıra gidiyordu:

$$E(y_{t+h}|y_t) = \rho_1^h y_t, \text{ her } h \geq 1 \text{ için.}$$

- Random walk sürecinde y_t ile y_{t+h} arasındaki korelasyon büyük t'ler için 1'e yakındır ve şu formülden hesaplanır: Eğer $Var(y_0) = 0$ ise,


$$Corr(y_t, y_{t+h}) = \sqrt{t/(t+h)}$$

- Dolayısıyla, bir **random walk** süreci durağan-olmayan (**nonstationary**) bir süreçtir.

Rassal Yürüyüş (Random Walk)

Figure 11.1

Two realizations of the random walk $y_t = y_{t-1} + e_t$, with $y_0 = 0$, $e_t \sim \text{Normal}(0,1)$, and $n = 50$.



Rassal Yürüyüş (Random Walk)

- ▶ **Random walk** süreci birim kök sürecinin (**unit root process**) özel bir halidir. AR(1)'de $\rho_1 = 1$ olduğu için süreç birim kök içermektedir.
- ▶ Çeşitli e_t süreçleri tanımlanarak pek çok değişik unit root süreci türetilir. Örneğin, e_t , MA(1) ya da kararlı AR(1) süreci izleyen zayıf bağımlı (weakly dependent) seriler olabilir.
- ▶ Ekonomik serilerin yüksek yapışkanlık gösterip göstermediğinin bilinmesi politika perspektifi açısından önemlidir. Yapışkan serilerde ciddi bir değişikliğe yol açan herhangi bir politikanın etkileri çok uzun süre devam edecektir.
- ▶ Yani, şoklar random walk süreçlerinde çok uzun ömre sahiptir, etkinin sıfıra gitmesi çok yavaş olur.

Yönlü Rassal Yürüyüş (Random Walk with Drift)

- ▶ Bir sabit terim (intercept) içeren rassal yürüyüş, "yönlü rassal yürüyüş" (**random walk with drift**) denir.

$$y_t = \alpha_0 + y_{t-1} + e_t, t = 1, 2, \dots$$

- ▶ $\{e_t : t = 1, 2, \dots\}$ ve y_0 , pür rassal yürüyüş (pure random walk) modelindeki özellikleri taşımaktadır. Yeni eklenen α_0 parametresine "sürüklemeye terimi" (drift term) denilmektedir.
- ▶ y_t 'nin beklenen değerinin doğrusal zaman trendi takip ettiğini yinelemeli yerine koyma yöntemi ile görmekteyiz:

$$y_t = \alpha_0 t + e_t + e_{t-1} + \dots + e_1 + y_0$$

Yönlü Rassal Yürüyüş (Random Walk with Drift)


- ▶ $y_0 = 0$ ise $E(y_t) = \alpha_0 t$: y_t 'nin beklenen değeri t'nin bir fonksiyonudur, eğer $\alpha_0 > 0$ ise y_t zamanla birlikte artmakta, $\alpha_0 < 0$ ise zamanla birlikte azalmaktadır.
- ▶ Pür rassal yürüyüş modeli ile benzer yol takip edersek:

$$E(y_{t+h}|y_t) = \alpha_0 h + y_t$$

- ▶ Buna göre t döneminde y_{t+h} 'in en iyi tahmini, $\alpha_0 h$ büyüklüğünde bir sürüklemeye terimi ile y_t olacaktır. y_t 'nin varyansı pür rassal yürüyüş süreci ile aynıdır.

Figure 11.2


The U.S. three-month T-bill rate, for the years 1948–1996.



Yönlü Rassal Yürüyüş (Random Walk with Drift)

Figure 11.3

A realization of the random walk with drift, $y_t = 2 + y_{t-1} + e_t$, with $y_0 = 0$, $e_t \sim \text{Normal}(0,9)$, and $n = 50$. The dashed line is the expected value of y_t , $E(y_t) = 2t$.



Kuvvetlice Yapışkan Zaman Serilerinin Dönüştürülmesi

- Birim kök (**unit root**) süreci izleyen, dolayısıyla da çok güçlü yapışkanlık (**strong persistence**) gösteren zaman serilerinin regresyonda kullanılması, bizi, CLM varsayımlarının ihlal edilmesi durumunda çok yanıltıcı sonuçlara götürebilir.
- Buna sahte (**spurious**) regresyon sorunu denir. Bu konu Ch.18'de ayrıntılı biçimde işlenmektedir.
- Bu nedenle, birim kök (unit root) süreçlerini önce zayıf bağımlı (weakly dependent) hale dönüştürecek, sonra regresyonda kullanacağız.
- Weakly dependent süreçlere "sıfırıncı dereceden entegre" (**integrated of order zero**) seri denir ve **I(0)** diye gösterilir. Bu serileri doğrudan regresyonda kullanabiliriz. Bu serilerin ortalamaları standart merkezi limit teoremlerini sağlar.

Kuvvetlice Yapışkan Zaman Serilerinin Dönüştürülmesi

- Rassal yürüyüş (random walk) gibi birim kök süreçleri "**birinci dereceden entegre**" dirler ve **I(1)** diye gösterilirler. Bu serilerin 1. farkı (first difference) "**sıfırıncı dereceden entegre**" seridir, **I(0)**.
- $y_t = y_{t-1} + e_t$, RW sürecini ele alalım. Eşitliğin her iki tarafından y_{t-1} 'i çıkarırsak serinin 1. farkını buluruz:

$$\Delta y_t = y_t - y_{t-1} = e_t, t = 2, 3, \dots$$

- Bu bir I(0) seridir.
- Pek çok ekonomik zaman serileri kesin pozitif (**strictly positive**) ve logaritmik olarak 1. dereceden entegrelerdir, I(1). Bu tür serilerin 1. farklarını regresyonda kullanacağız:

$$\Delta \log y_t = \log y_t - \log y_{t-1}$$

- Yani, logaritmik hali I(1) olan değişkenlerin büyüme hızları I(0)'dır ve regresyonda bunları kullanacağız.

Kuvvetlice Yapışkan Zaman Serilerinin Dönüştürülmesi

- ▶ $I(1)$ serinin regresyonda kullanmadan önce farkının alınması serideki zaman trendini de bertaraf eder. Örneğin, trend içeren şu seriyi ele alalım:

$$y_t = \gamma_0 + \gamma_1 t + v_t$$

- ▶ Bu seriyi $t - 1$ dönemi için yazalım

$$y_{t-1} = \gamma_0 + \gamma_1(t-1) + v_{t-1}$$

- ▶ İkisnin farkını alalım:

$$\Delta y_t = y_t - y_{t-1} = \gamma_1 + \Delta v_t$$

- ▶ Bu son ifadenin beklenen değerini alalım:

$$E[\Delta y_t] = \gamma_1 + E[\Delta v_t] = \gamma_1$$

- ▶ Yani, $E[\Delta y_t]$ bir sabite eşittir. Demek ki, trend içeren serinin 1. farkının ortalaması sabite eşittir ve biz bu durağan seriyi artık regresyonda kullanabiliriz.

Bir Serinin $I(1)$ ya da $I(0)$ Olduğuna Nasıl Karar Veririz?

- ▶ Bunun için **birim kök testleri** geliştirilmiştir. Bunlar Ch.18'de ele alınacaktır.
- ▶ Bu testlerin dışında bir çok informal yöntemler bulunmaktadır. Örneğin, $AR(1)$ sürecinde ρ_1 katsayısı mutlak olarak 1'den küçükse süreç $I(0)$, bire eşitse $I(1)$ olacaktır.
- ▶ $\rho_1 = \text{corr}(y_t, y_{t-1})$ olduğu için y_t ve y_{t-1} serileri arasındaki örnek korelasyonundan ρ_1 tahmin edilir ve karar verilir. $\text{corr}(y_t, y_{t-1})$, y_t serisinin, "**1. sıra otokorelasyonu**"dur (**first order autocorrelation**).
- ▶ $|\rho_1| < 1$ iken, $\hat{\rho}_1$, kitle parametresi ρ_1 'in tutarlı ancak sapmalı bir tahmin edicisidir.

Bir Serinin $I(1)$ ya da $I(0)$ Olduğuna Nasıl Karar Veririz?

- ▶ Bilinmeyen ρ_1 için örnek değerlerinden bir güven aralığı tesis edip bu aralığın 1'i içerip içermediğine bakabiliriz.
- ▶ Ancak sorun şudur: Bilinmeyen kitle parametresi ρ_1 'in 1'e yakın değerler alması durumunda $\hat{\rho}_1$ 'in örnek dağılımı oldukça farklı çıkmakta ve $\hat{\rho}_1$ aşağı doğru büyük bir sapma göstermektedir.
- ▶ Pratikte çoğu kez $\hat{\rho}_1$ 'in 0.90 ve üzerinde çıkması serinin birincil farkının alınması için yeterli bir sebep olarak görülür. Bazıları bu oranı 0.8'e kadar indirebilmektedirler.
- ▶ Seride trend varsa önce bu trendi alıp $\hat{\rho}_1$ 'i daha sonra tahmin etmek gerekir. Trend $\hat{\rho}_1$ 'in olduğundan yüksek (overestimated) çıkmasına sebep olur.

Example 11.6: Doğurganlık Modeli

- ▶ gfr: doğurganlık oranı, pe: vergi muafiyeti miktarı. Bu serilerin 1. sıradan otokorelasyonları hayli büyüktür, gfr için $\hat{\rho}_1 = 0.977$ ve pe için $\hat{\rho}_1 = 0.964$. Bunlar birim kök sürecini işaret etmektedir ve OLS t istatistiklerinin kullanımı konusunda soru işareti yaratmaktadırlar.
- ▶ Modelleri, serilerin 1. farklarını alarak tahmin edelim:

$$\widehat{\Delta \text{gfr}_t} = -0.785 - 0.043 \Delta \text{pe}_t$$

(0.502) (0.028)

$$n = 71 \quad R^2 = 0.032 \quad \bar{R}^2 = 0.018$$

$$\widehat{\Delta \text{gfr}_t} = -0.964 - 0.036 \Delta \text{pe}_t - 0.014 \Delta \text{pe}_{t-1} + 0.110 \Delta \text{pe}_{t-2}$$

(0.468) (0.027) (0.028) (0.027)

$$n = 69 \quad R^2 = 0.233 \quad \bar{R}^2 = 0.197$$

Example 11.7: Ücretler ve Üretkenlik

- Saatlik ücretin, saatlik üretim miktarına esnekliğini bulmak amacıyla aşağıdaki model kurulmuştur:

$$\log(hr\text{wage}_t) = \beta_0 + \beta_1 \log(outphr_t) + \beta_2 t + u_t$$

- Modelde, hrwage ortalama saatlik ücret, outphr saatlik üretim miktarı, t ise zaman trendidir. Modelin tahmini aşağıda verilmektedir:

$$\widehat{\log(hr\text{wage}_t)} = \underset{(0.37)}{-5.33} + \underset{(0.09)}{1.64} \log(outphr_t) - \underset{(0.002)}{0.018} t$$

$$n = 41 \quad R^2 = 0.971 \quad \bar{R}^2 = 0.970$$

Example 11.7: Ücretler ve Üretkenlik

- Regresyon sonuçlarına dikkatle yaklaşılmalıdır. $\log(hr\text{wage})$ doğrusal trendden arındırıldıktan sonra bile, 1. sıradan otokorelasyonu 0.967'dir, trendden arındırılmış $\log(outphr)$ 'nin ise $\hat{\rho}_1 = 0.945$. Bunlar, iki serinin birim kök içerdiğini öne sürmektedir, 1. farklarla tekrar tahmin yapalım (artık zaman trendine ihtiyacımız kalmadı):

$$\Delta \widehat{\log(hr\text{wage}_t)} = \underset{(0.0042)}{-0.0036} + \underset{(0.173)}{0.809} \Delta \log(outphr_t)$$

$$n = 40 \quad R^2 = 0.364 \quad \bar{R}^2 = 0.348$$